

=====

数据质量报告

=====

【基本信息】

总记录数: 3066766

总列数: 19

=====

【缺失值分析】

=====

存在缺失值的列:

passenger_count: 71743.0 (2.34%)

RatecodeID: 71743.0 (2.34%)

store_and_fwd_flag: 71743.0 (2.34%)

congestion_surcharge: 71743.0 (2.34%)

airport_fee: 71743.0 (2.34%)

总计缺失值数量: 358715

=====

【异常值分析】

=====

(1) 时间异常 (上车时间 $\geq$ 下车时间): 1121 条

占比: 0.04%

(2) 乘客数量异常 (≤ 0 或 > 6): 51184 条

占比: 1.67%

最小值: 0.0

最大值: 9.0

(3) 行驶距离异常 (≤ 0 或 ≥ 100): 45950 条

占比: 1.50%

最小值: 0.0

最大值: 258928.15

(4) 车费金额异常 (≥ 1000 或 ≤ 0): 25774 条

占比: 0.84%

最小值: -900.0

最大值: 1160.1

```
=====
【异常值汇总】
=====

存在至少一种异常的记录总数：118263
异常记录占比：3.86%
完全正常的记录数：2948503
正常记录占比：96.14%

=====
【异常数据示例】
=====

前10条异常记录：
VendorID tpep_pickup_datetime tpep_dropoff_datetime passenger_count trip_distance fare_amount
3 1 2023-01-01 00:03:48 2023-01-01 00:13:25 0.0 1.90 12.1
132 2 2023-01-01 00:28:29 2023-01-01 00:31:03 1.0 0.42 -5.1
263 2 2023-01-01 00:20:18 2023-01-01 00:27:56 2.0 1.19 -9.3
278 2 2023-01-01 00:39:02 2023-01-01 00:46:03 1.0 0.00 7.9
279 2 2023-01-01 00:47:29 2023-01-01 00:55:49 1.0 0.00 8.6
280 2 2023-01-01 00:59:24 2023-01-01 01:14:26 1.0 0.00 13.5
324 2 2023-01-01 00:52:22 2023-01-01 01:14:03 1.0 4.89 -25.4
333 1 2023-01-01 00:57:44 2023-01-01 00:57:59 1.0 0.00 3.0
398 2 2023-01-01 00:28:04 2023-01-01 00:28:35 1.0 0.00 70.0
442 2 2023-01-01 00:37:17 2023-01-01 00:38:51 1.0 0.00 40.0

=====
报告生成完毕
=====
```

```
=====
数据清洗开始
=====
```

原始数据记录数：3066766

(1) 删除包含NaN的行...

删除了 71743 条记录

剩余记录数：2995023

(2) 删除passenger_count异常的记录 (<=0 或 >6)...

删除了 51184 条记录

剩余记录数：2943839

(3) 删除上车时间 >= 下车时间的记录...

删除了 1006 条记录

剩余记录数：2942833

(4) 处理trip_distance...

删除trip_distance <= 0的记录：36238 条

删除trip_distance > 350的记录：19 条

添加long_trip标签：19 条记录标记为长途行程

剩余记录数：2906576

(5) 处理total_amount...

删除了 22211 条记录 (total_amount <= 0 或 >= 1000)

剩余记录数：2884365

```
=====
数据清洗完成
=====
```

```
=====
特征工程开始
=====
```

(1) 提取上车时间的小时和星期...

pickup_hour范围: 0 - 23

pickup_day范围: 1 (周一) - 7 (周日)

(2) 提取下车时间的小时...

dropoff_hour范围: 0 - 23

(3) 创建is_peak列 (高峰期标记) ...

高峰期行程数量: 697152

非高峰期行程数量: 2187213

高峰期占比: 24.17%

(4) 创建pre_distance_profit列 (单位距离收益) ...

pre_distance_profit统计信息:

平均值: 15.83

最小值: 0.02

最大值: 48420.00

中位数: 10.92

```
=====
特征工程完成
=====
```

新增列: pickup_hour, pickup_day, dropoff_hour, is_peak, pre_distance_profit

当前总列数: 25

当前记录数: 2884365

```
=====
最终数据结构预览
=====
```

前5行数据:

	pickup_hour	pickup_day	...	total_amount	pre_distance_profit
0	0	7	...	14.30	14.742268
1	0	7	...	16.90	15.363636
2	0	7	...	34.90	13.904382
4	0	7	...	19.68	13.762238
5	0	7	...	27.80	15.108696

[5 rows x 7 columns]

```
=====
全部处理完成
=====
```

```
=====
可视化分析：出行需求时间分布
=====
```

(1) 绘制小时平均订单量折线图...

已保存: output/hourly_order_distribution.png

(2) 绘制工作日vs周末平均订单量柱状图...

已保存: output/workday_weekend_comparison.png

```
=====
可视化分析完成
=====
```

生成的图表文件:

1. output/hourly_order_distribution.png - 每小时平均订单量分布
2. output/workday_weekend_comparison.png - 工作日与周末对比

```
=====
可视化分析：区域热度分布
=====
```

```
(1) 绘制上客热度分布堆叠柱状图...
```

```
已保存：output/pickup_location_heatmap.png
```

```
(2) 绘制下客热度分布堆叠柱状图...
```

```
已保存：output/dropoff_location_heatmap.png
```

```
=====
区域热度分布分析完成
=====
```

```
生成的图表文件：
```

1. output/pickup_location_heatmap.png - 上客热度分布 TOP 10
2. output/dropoff_location_heatmap.png - 下客热度分布 TOP 10

```
=====
可视化分析：车费影响因素
=====
```

(1) 绘制时段-车费散点图...

已保存：output/hour_vs_fare_scatter.png

(2) 绘制时段-小费散点图...

已保存：output/hour_vs_tip_scatter.png

(3) 绘制乘客数-车费散点图...

已保存：output/passenger_vs_fare_scatter.png

```
=====
车费影响因素分析完成
=====
```

生成的图表文件：

1. output/hour_vs_fare_scatter.png - 时段与车费关系
2. output/hour_vs_tip_scatter.png - 时段与小费关系
3. output/passenger_vs_fare_scatter.png - 乘客数与车费关系


```
=====
可视化分析：长途旅行单位距离收益
=====
```

```
(1) 绘制每趟长途旅行的单位距离收益柱状图...
```

```
已保存: output/long_trip_profit_detail.png
```

```
(2) 绘制长途与非长途平均单位距离收益对比柱状图...
```

```
已保存: output/long_vs_normal_profit_comparison.png
```

```
=====
长途旅行单位距离收益分析完成
=====
```

```
生成的图表文件：
```

1. output/long_trip_profit_detail.png - 每趟长途旅行的单位距离收益
2. output/long_vs_normal_profit_comparison.png - 长途与非长途平均收益对比

```
统计信息：
```

```
长途旅行平均单位距离收益：$3.53/mile
```

```
非长途旅行平均单位距离收益：$15.83/mile
```

```
差异：$12.29/mile
```

```
=====
机器学习：出行需求预测模型（PyTorch）
=====
```

(1) 筛选订单量最高的上客点...

订单量最高的上客点ID: 132

总订单数: 152148

筛选后数据量: 152148

(2) 构建特征数据集...

聚合后的数据量: 750

(3) 划分训练集和测试集...

训练集大小: 604 (1月1日-1月25日)

测试集大小: 146 (1月26日-1月31日)

(4) 准备特征和标签...

(5) 特征标准化...

训练集特征形状: (604, 3)

测试集特征形状: (146, 3)

(6) 转换为PyTorch张量...

训练批次数量: 19

(7) 定义神经网络模型...

```
DemandPredictionModel(  
    (network): Sequential(  
      (0): Linear(in_features=3, out_features=64, bias=True)  
      (1): ReLU()  
      (2): Linear(in_features=64, out_features=32, bias=True)  
      (3): ReLU()  
      (4): Linear(in_features=32, out_features=1, bias=True)  
    )  
  )  
)
```

(8) 训练模型...

```
Epoch [10/100], Train Loss: 0.3057, Train MAE: 0.4427, Train RMSE: 0.5529, Val Loss: 0.3383, Val MAE: 0.4293, Val RMSE: 0.5816  
Epoch [20/100], Train Loss: 0.2770, Train MAE: 0.4200, Train RMSE: 0.5263, Val Loss: 0.3264, Val MAE: 0.4094, Val RMSE: 0.5713  
Epoch [30/100], Train Loss: 0.2556, Train MAE: 0.4084, Train RMSE: 0.5056, Val Loss: 0.2977, Val MAE: 0.3914, Val RMSE: 0.5456  
Epoch [40/100], Train Loss: 0.2337, Train MAE: 0.3854, Train RMSE: 0.4835, Val Loss: 0.2870, Val MAE: 0.3780, Val RMSE: 0.5357  
Epoch [50/100], Train Loss: 0.2188, Train MAE: 0.3729, Train RMSE: 0.4678, Val Loss: 0.2850, Val MAE: 0.3846, Val RMSE: 0.5339  
Epoch [60/100], Train Loss: 0.2076, Train MAE: 0.3690, Train RMSE: 0.4556, Val Loss: 0.2812, Val MAE: 0.3809, Val RMSE: 0.5303  
早停触发于 epoch 65
```

实际训练轮数: 65

(9) 绘制Loss曲线...

已保存: output/model_training_curves.png

(10) 在测试集上进行预测...

(11) 计算评估指标...

=====

测试集评估报告

=====

MAE (平均绝对误差): 48.47 订单/小时
RMSE (均方根误差): 67.44 订单/小时
测试集实际订单量范围: [1, 466]
测试集预测订单量范围: [12.25, 336.15]

相对MAE: 27.75%
相对RMSE: 38.61%

(12) 绘制预测vs实际值对比图...

已保存: output/prediction_vs_actual.png

(13) 预测1月30日17时的订单量...

预测时间: 2023年1月30日 (星期1) 17时

=====

预测结果

=====

上客点ID: 132
预测时间: 2023年1月30日 17:00
预测订单量: 275.59 单

=====

(14) 保存模型...

模型已保存: output/demand_prediction_model.pth

=====

出行需求预测模型完成

```
=====
随机森林测试集评估报告
=====
```

```
MAE (平均绝对误差): 35.56 订单/小时
RMSE (均方根误差): 53.09 订单/小时
测试集实际订单量范围: [1, 466]
测试集预测订单量范围: [8.09, 327.70]
```

```
(8) 预测1月30日17时的订单量...
```

```
=====
随机森林预测结果
=====
```

```
上客点ID: 132
预测时间: 2023年1月30日 17:00
预测订单量: 308.08 单
=====
```

```
(9) 保存随机森林模型...
```

```
模型已保存: output/random_forest_model.pkl
```

```
=====
随机森林预测模型完成
=====
```

```
=====
机器学习：随机森林预测模型
=====
```

(1) 筛选订单量最高的上客点...

订单量最高的上客点ID: 132

(2) 构建特征数据集...

聚合后的数据量: 750

(3) 划分训练集和测试集...

训练集大小: 604 (1月1日-1月25日)

测试集大小: 146 (1月26日-1月31日)

(4) 准备特征和标签...

(5) 训练随机森林模型...

随机森林模型训练完成

(6) 在测试集上进行预测...

(7) 计算评估指标...

```
=====
模型对比：神经网络 vs 随机森林
=====

=====
模型性能对比
=====

指标                神经网络                随机森林                差异
-----
MAE                  48.47                  35.56                  12.91
RMSE                 67.44                  53.09                  14.36
=====

MAE更优的模型： 随机森林
RMSE更优的模型： 随机森林

(1) 绘制MAE和RMSE对比柱状图...
    已保存： output/model_comparison_mae_rmse.png

(2) 绘制预测vs实际值对比图...
    已保存： output/model_prediction_comparison.png

(3) 绘制误差分布对比图...
    已保存： output/model_error_distribution.png

(4) 绘制实际值vs预测值散点图...
    已保存： output/model_scatter_comparison.png
```

```
=====
模型对比分析完成
=====
```

生成的对比图表：

1. output/model_comparison_mae_rmse.png - MAE和RMSE对比柱状图
2. output/model_prediction_comparison.png - 预测结果对比图
3. output/model_error_distribution.png - 误差分布对比图
4. output/model_scatter_comparison.png - 实际值vs预测值散点图

最终预测结果对比（1月30日17时）：

神经网络预测：275.59 单
随机森林预测：308.08 单
差异：32.49 单

进程已结束，退出代码为 0